Repte Octubre - Models de classificació

```
In [65]: #!pip install sklearn
In [478... # Tratamiento de datos
        import pandas as pd
        import numpy as np
        # Gráficos
        import matplotlib.pyplot as plt
        from matplotlib import style
        import matplotlib.ticker as ticker
        import seaborn as sns
        from pprint import pprint
        # Preprocesado v análisis
        #import statsmodels.api as sm
        #import pingouin as pa
        from scipy import stats
        import random as rd
        from imblearn.over sampling import SMOTE
        # Preprocesado y modelado
        from sklearn.datasets import load boston
        from sklearn.ensemble import RandomForestRegressor
        from sklearn.metrics import mean absolute error
        from sklearn.metrics import mean squared error
        from sklearn.metrics import confusion matrix, precision score, recall score, accuracy score
        from sklearn import metrics
        from sklearn.metrics import classification report
        from sklearn.metrics import f1 score
        from sklearn import metrics
        from sklearn.model selection import cross val score
        from sklearn.model_selection import train_test_split
```

```
from sklearn.model selection import RepeatedKFold
from sklearn.model selection import GridSearchCV
from sklearn.model selection import ParameterGrid
from sklearn.tree import DecisionTreeClassifier
from sklearn.tree import plot tree
from sklearn.tree import export text
from sklearn.inspection import permutation importance
import multiprocessing
from sklearn import neighbors, datasets, preprocessing
from sklearn.preprocessing import Normalizer
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import PolynomialFeatures
from sklearn.preprocessing import LabelEncoder
from sklearn.model selection import KFold
import statsmodels.api as sm
from sklearn.model selection import cross val predict
from sklearn.naive bayes import GaussianNB
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn import svm
from sklearn.pipeline import Pipeline
from sklearn.feature selection import VarianceThreshold
# Test Estadísticos
# ------
from scipy.stats import shapiro
from scipy.stats import ttest ind
from scipy.stats import ttest rel
# Ajuste de distribuciones
from scipy import stats
import inspect
from statsmodels.distributions.empirical distribution import ECDF
# Configuración matplotlib
# ------
plt.style.use('ggplot')
from statsmodels.graphics.gofplots import qqplot
from matplotlib import pyplot
```

1. DataFrame

y.head(3)

Features: El dataset contiene 6 features en 6 columnas, que son los parámetros medidos por los diferentes sensores. Estos corresponden a las vibraciones detectadas en ciertos puntos de la ladera del volcán.

Target: El target corresponde al 'label' que clasifica los tipos de erupciones volcánicas en función de los features medidos por los sensores.

- Target 0 corresponde a una erupción de tipo Pliniana
- Target 1 corresponde a una erupción de tipo Peleana
- Target 2 corresponde a una erupción de tipo Vulcaniana
- Target 3 corresponde a una erupción de tipo Hawaiana
- Target 4 corresponde a una erupción de tipo Estromboliana

```
df= pd.read_csv(r"C:\Users\hecto\OneDrive\Documentos\IT Data Science\Reto octubre\data\jm_train.csv",header=0)
           df.shape
 In [480...
           (2100, 7)
Out[480]:
           df.head(3)
 In [481...
Out[481]:
                                  feature3
                                           feature4
                                                      feature5
                                                                feature6 target
               feature1
                         feature2
              0.474335
                         0.881640 -2.050543 -1.251935 -1.035151 -1.934367
              -1.034675
                                           -1.555989 -0.337553 -2.473838
                         1.741801
                                 -1.660629
           2 -0.563221 -0.688381 -0.318415 -1.845172 0.352366 -0.912928
 In [482... y=df["target"]
```

```
Out[482]:
           Name: target, dtype: int64
          data test= pd.read csv(r"C:\Users\hecto\OneDrive\Documentos\IT Data Science\Reto octubre\data\jm X test.csv",header=0)
          data_test.head(3)
 In [484...
Out[484]:
                                          feature4 feature5 feature6
              feature1 feature2 feature3
           0 0.943723 -2.985473 -0.938218
                                          3.580261 -3.038106 2.080338
           1 -0.899819 1.295568
                                 1.274513
                                         0.718186
                                                   1.117035 0.463068
           2 0.293281 -0.099317 1.874902 -0.589582 1.828441 1.011596
          data_test.shape
 In [485...
           (900, 6)
Out[485]:
```

2. Análisis Exploratorio

2.1 Check null values

```
In [486... print('The dataset has', df.shape[0], 'rows and', df.shape[1], 'columns.')
The dataset has 2100 rows and 7 columns.
In [487... df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2100 entries, 0 to 2099
Data columns (total 7 columns):
    Column
             Non-Null Count Dtype
    _____
             -----
    feature1 2100 non-null float64
    feature2 2100 non-null float64
 2 feature3 2100 non-null float64
 3 feature4 2100 non-null float64
 4 feature5 2100 non-null float64
 5 feature6 2100 non-null
                           float64
    target
             2100 non-null
                           int64
dtypes: float64(6), int64(1)
memory usage: 115.0 KB
```

In [488... df.describe().round(2).T

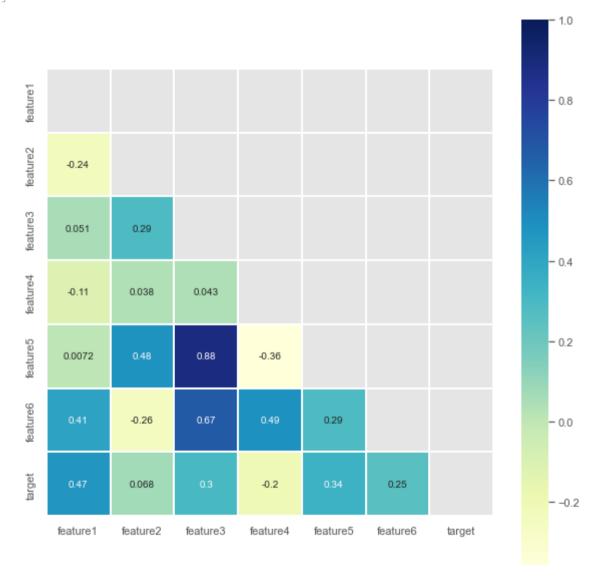
Out[488]:

	count	mean	std	min	25%	50%	75%	max
feature1	2100.0	-0.20	1.54	-6.68	-1.17	-0.44	0.89	4.57
feature2	2100.0	0.20	1.61	-5.38	-0.88	0.32	1.32	6.70
feature3	2100.0	-0.38	1.45	-6.15	-1.37	-0.44	0.66	4.16
feature4	2100.0	-0.21	1.44	-5.65	-1.26	-0.18	0.87	4.37
feature5	2100.0	-0.19	1.50	-5.91	-1.21	-0.20	0.85	5.07
feature6	2100.0	-0.43	1.19	-4.43	-1.13	-0.41	0.35	4.02
target	2100.0	1.98	1.41	0.00	1.00	2.00	3.00	4.00

2.2 Matriz de Correlaciones

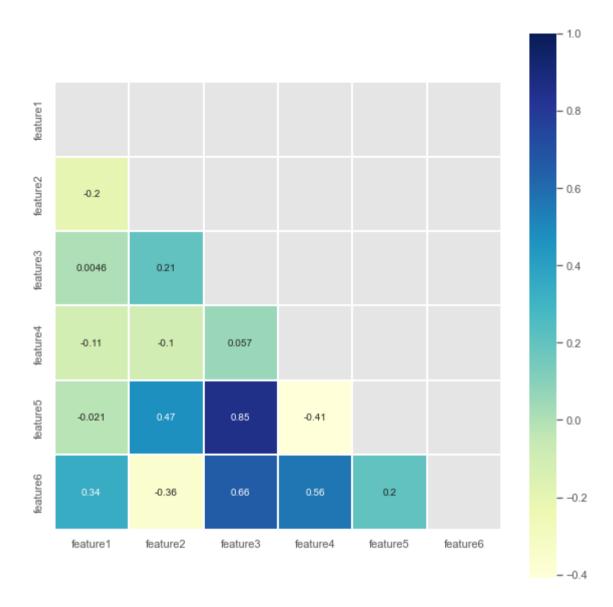
2.2.1 Matriz ce correlaciones del data inicial

```
In [489... plt.figure(figsize=(10,10))
         corr = df.corr()
         upp mat = np.triu(corr)
         colormap = plt.cm.YlGnBu
         sns.heatmap(corr,linewidths=0.1,vmax=1.0,cmap=colormap,linecolor='white', square = True,annot=True,mask = upp mat)
```



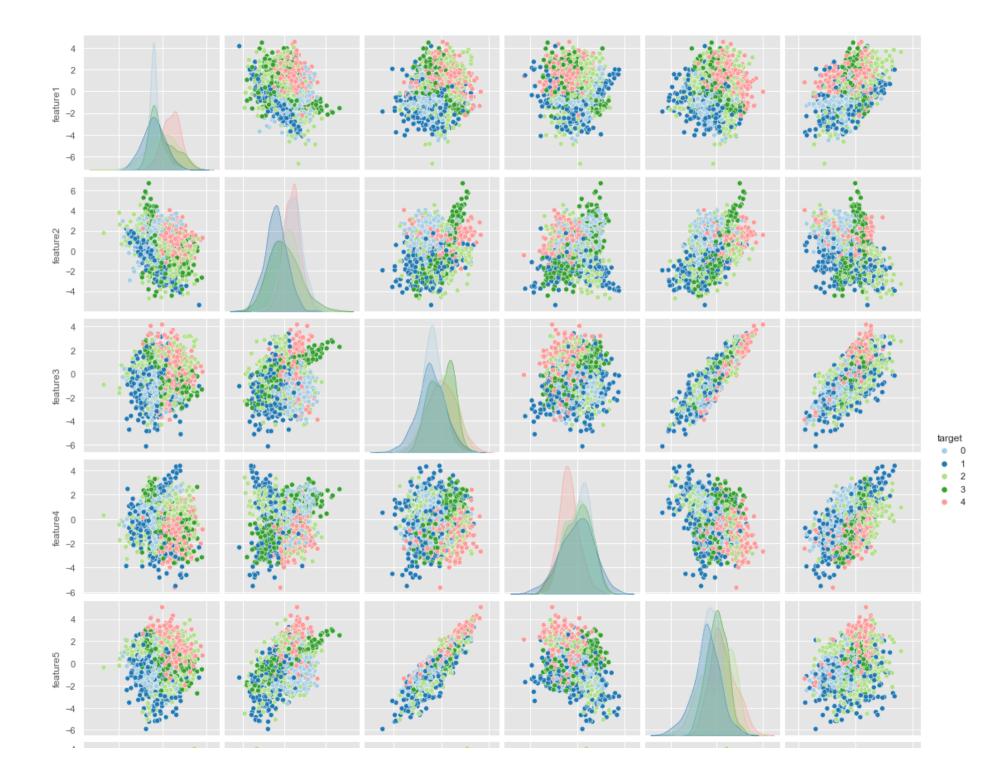
- Entre la variable objetivo y las variables explicativas, existe una correlación que no supera el (+-) 0.3 con la mayoría de variables, salvo con feature1 que es del 0.47.
- También se producen correlaciones elevadas entre las variables explitativas, superiores en varios casos al (+-) 0.8 por lo que pueden darse problemas de multicolinealidad entre feature3 y 5

2.2.2 Matriz de correlaciones del data test



• Las correlaciones de data_test mantiene los mismos parámetros que la anterior

2.2.3 Gráficos por pares en función de la variable 'target'





En la distribución por pares se observa que existe una clara correlación entre algunas variables, por lo que vamos a analizar si este fenómeno nos afectará negativamente en nuestro modelo.

2.2.4 Estimación de la multicolinealidad con VIF (Variance Inflation Factor)

Según Hanke, y Wichern (2010) la multicolinealidad es la situación en la cual las variables independientes de una ecuación de regresión múltiple están sumamente intercorrelacionadas. Es decir, existe una relación lineal entre dos o más variables independientes. La multicolinealidad se refiere a que dos o más variables pueden contener información repetida. El impacto que tiene la multicolinealidad en las variables se puede medir mediante un indicador que se conoce como Factor de Inflación de la Varianza o VIF por sus siglas en inglés (variance inflation factor):

- VIF = $1/(1-R^2)$
- Si el valor de VIF es cercano a 1 se puede interpretar que la multicolinealidad no es un gran problema para la variable en cuestión. Un valor de VIF más grande que 1 implica que el coeficiente de esa variable puede ser modificado de manera importante conforme se tomen en cuenta a las demás variables en el modelo de regresión. En última instancia, un valor de VIF alto implica que existe información redundante en las variables independientesy que, por lo tanto, cada vez que una de estas variables se modifique, el coeficiente de otra variable puede ser afectado.
- La regla general para decidir sobre la corección de la multicolinealidad es la siguiente:
 - 1. VIF=1 significa que no existe correlación entre esta variable independiente y cualquier otra.
 - 2. 1 < VIF < 5 sugiere una correlación moderada pero no sería necesario resolverla.
 - 3. VIF > 5 son niveles críticos de multicolinealidad.

• El resultado Vif superior a 5 nos sugiere la posibilidad de que alguna de las variables pueda ser excluída, pero en nuestro caso, analizaremos el modelo con todas las variables, y excluiremos feature3 para ver si mejora o no las métricas, y en función de esos resultados se decidirá sobre la posibilidad de excluir alguna variable.

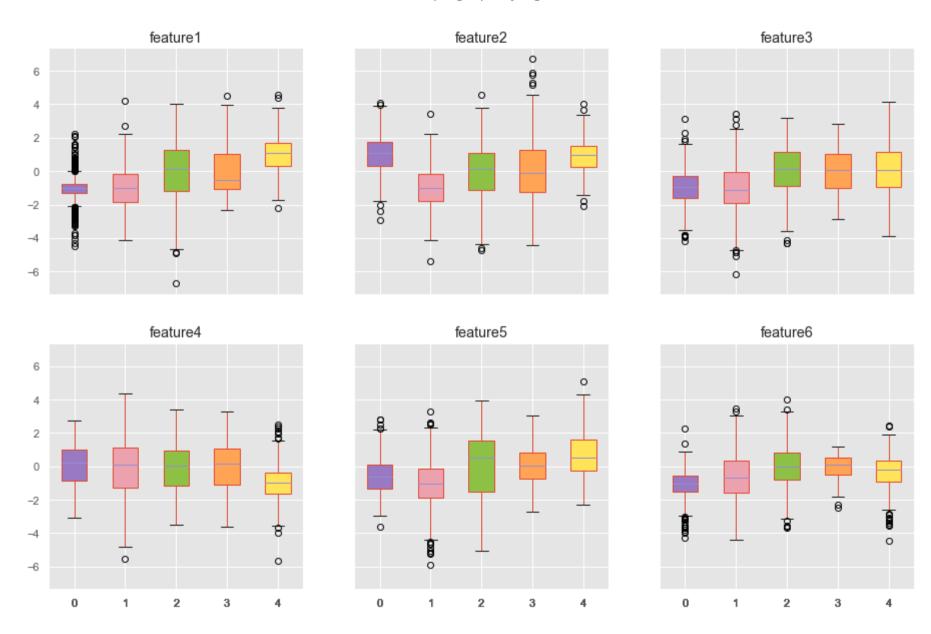
2.3 Distribución de las variables explicativas por tipo de 'target'

```
In [494...
bp_dict = df.boxplot(
by="target",layout=(2,3),figsize=(15,10),
    return_type='both',
    patch_artist = True,
)
colors =["#9979c1", "#eba2ae", "#8dc146", '#ffa455', '#ffe358', '#bde2f2']

for row_key, (ax,row) in bp_dict.iteritems():
    ax.set_xlabel('')

    for i,box in enumerate(row['boxes']):
        box.set_facecolor(colors[i])

plt.show()
```



• El gráfico boxplot muestra el coportamiento de la distribución de las variables en los diferentes percentiles en relación a la mediana, así como las variables con más outliers en función del tipo de clasificación.

• La Case Pliniana(0) es la que tiene más outliers en la distribución de la mayoría de variables explicativas,

3. Preprocesado de la información

```
In [495... df.isnull().values.any()
Out[495]: False
In [496... df.isna().values.any()
Out[496]: False
In [497... features = df.columns.values features
Out[497]: array(['feature1', 'feature2', 'feature4', 'feature5', 'feature5', 'feature6', 'target'], dtype=object)
```

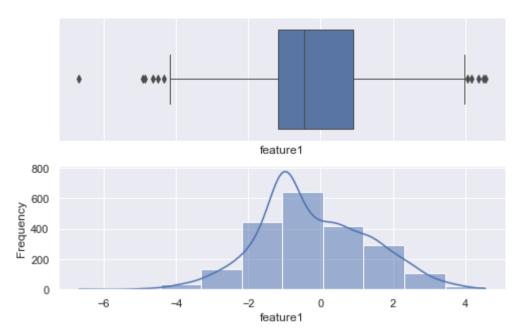
3.1 Gráficos de Frecuencia y boxplot de las variables del data set inicial

```
import matplotlib.pyplot as plt
import seaborn as sns

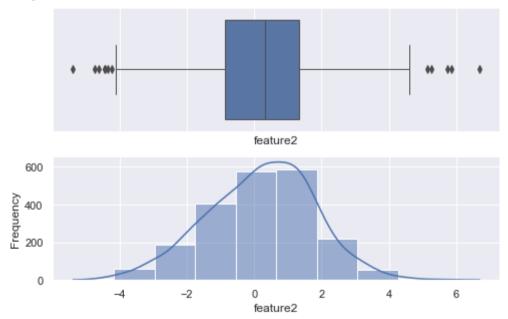
import warnings
warnings.filterwarnings("ignore")

for i in df.columns:
    plt.figure()
    plt.tight_layout()
    sns.set(rc={"figure.figsize":(8, 5)})
    f, (ax_box, ax_hist) = plt.subplots(2, sharex=True)
    plt.gca().set(xlabel= i,ylabel='Frequency')
    sns.boxplot(df[i], ax=ax_box, linewidth= 1.0)
    sns.histplot(df[i], ax=ax_hist, bins = 10,kde=True)
```

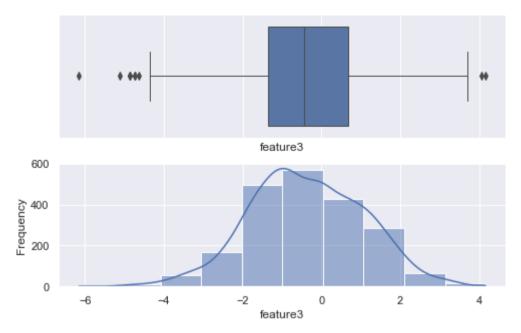
<Figure size 576x360 with 0 Axes>



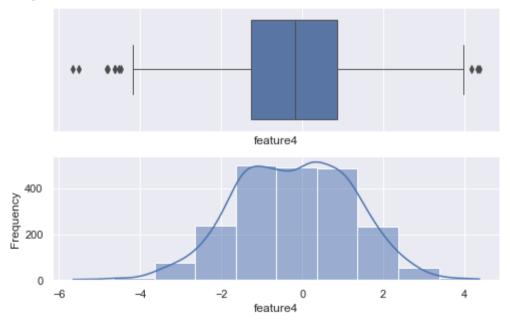
<Figure size 576x360 with 0 Axes>



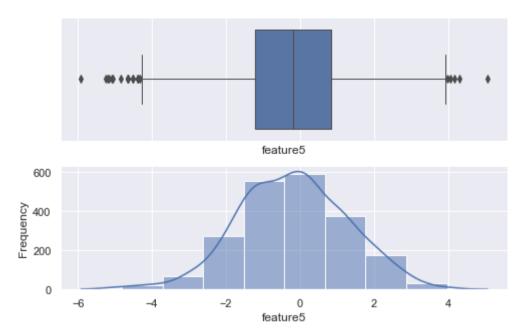
<Figure size 576x360 with 0 Axes>



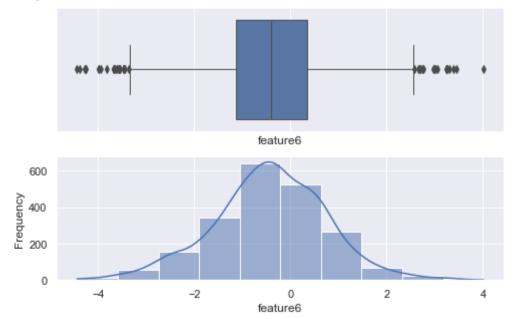
<Figure size 576x360 with 0 Axes>



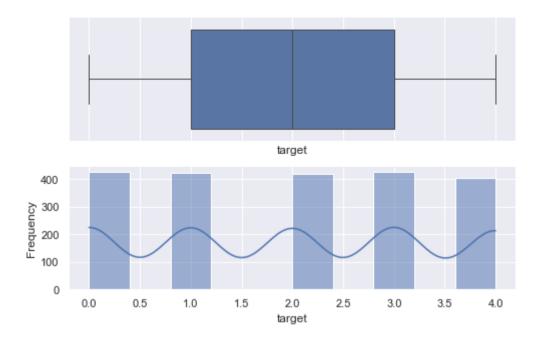
<Figure size 576x360 with 0 Axes>



<Figure size 576x360 with 0 Axes>



<Figure size 576x360 with 0 Axes>



3.2 Análisis de la normalidad

In [500... check_normal_distribution(df[features])

```
Results for feature1:
stat=0.989, p=0.000
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
Results for feature2:
stat=0.996, p=0.000
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
Results for feature3:
stat=0.998, p=0.005
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
Results for feature4:
stat=0.997, p=0.000
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
Results for feature5:
stat=0.998, p=0.004
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
Results for feature6:
stat=0.995, p=0.000
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
Results for target:
stat=0.889, p=0.000
Reject null hypothesis at 95% Significance Level >> The data is not normally distributed
______
```

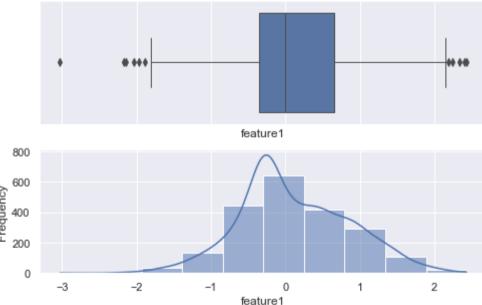
• Ninguna variable se distribuye normalmente

3.3 RobustScaler

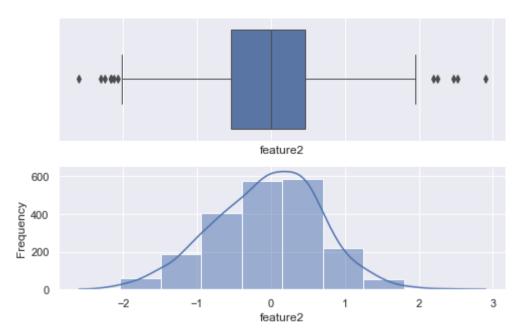
• Ninguna variable expicativa sigue una distribución normal, se aplica RobustScaler, para solucionar los outliers que apararcen en muchas de las variables.

```
In [501... from sklearn.preprocessing import RobustScaler
    df=df.drop(["target"],axis=1)
    features2 = df.columns.values
    features2
```

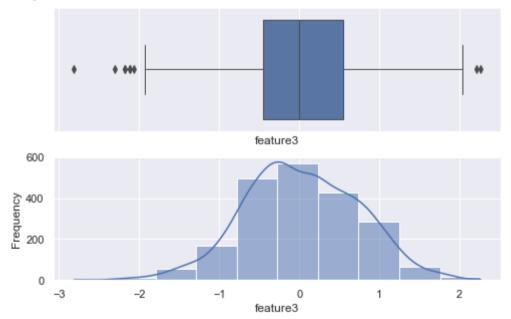
```
array(['feature1', 'feature2', 'feature3', 'feature4', 'feature5',
Out[501]:
                  'feature6'], dtype=object)
 In [502... from sklearn.preprocessing import RobustScaler
          normColumns = features2
          scalerNorm = preprocessing.RobustScaler().fit(df[normColumns])# RobustEscaler
          df[normColumns] = scalerNorm.transform(df[normColumns])
In [503... for i in df.columns:
              plt.figure()
              plt.tight layout()
              sns.set(rc={"figure.figsize":(8, 5)})
              f, (ax box, ax hist) = plt.subplots(2, sharex=True)
              plt.gca().set(xlabel= i,ylabel='Frequency')
              sns.boxplot(df[i], ax=ax box , linewidth= 1.0)
              sns.histplot(df[i], ax=ax hist , bins = 10,kde=True)
          <Figure size 576x360 with 0 Axes>
```



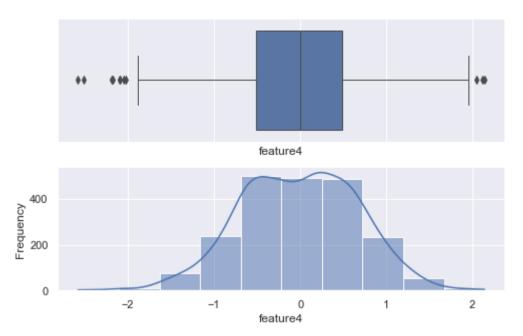
<Figure size 576x360 with 0 Axes>



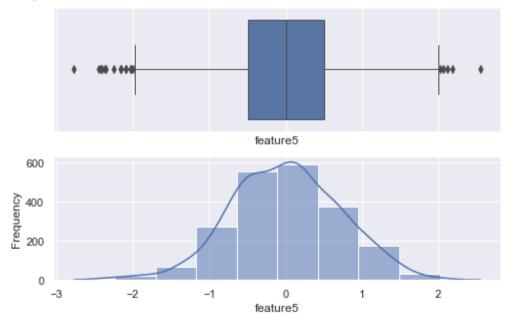
<Figure size 576x360 with 0 Axes>



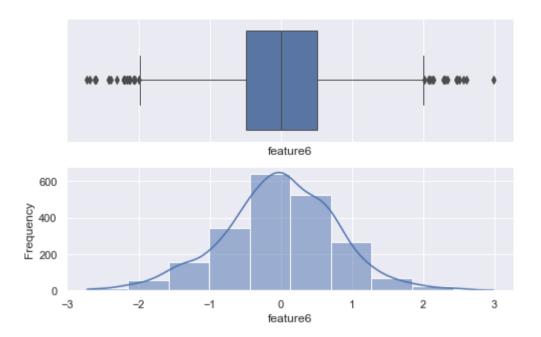
<Figure size 576x360 with 0 Axes>



<Figure size 576x360 with 0 Axes>



<Figure size 576x360 with 0 Axes>

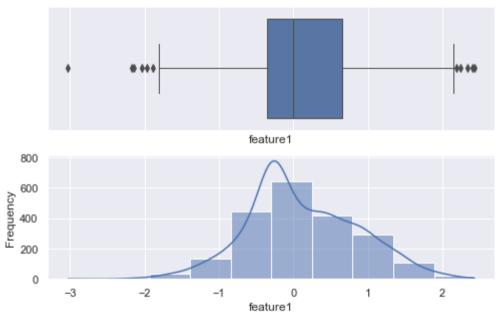


- Las estadísticas de centrado y escalamiento de RobustScaler se basan en percentiles y no están influenciadas por unos pocos valores atípicos marginales muy grandes.
- El rango resultante de los valores de las características transformadas es mayor que para la estandarización o normalización y son aproximadamente similares. La mayoría de los valores transformados se encuentran en un rango [-3, 3].
- Los valores atípicos todavía están presentes en los datos transformados. Si se desearamos un recorte de valores atípicos por separado, se debería aplicar una transformación no lineal.

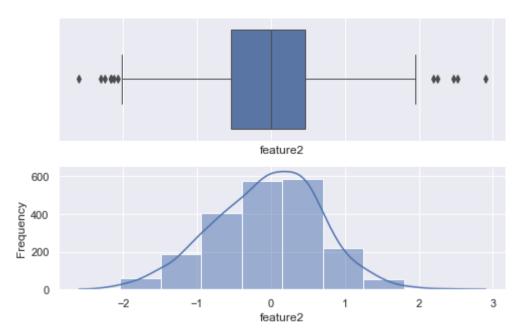
3.4 Robust Scaler de data_test

for i in df_test.columns: plt.figure() plt.tight_layout() sns.set(rc={"figure.figsize":(8, 5)}) f, (ax_box, ax_hist) = plt.subplots(2, sharex=True) plt.gca().set(xlabel= i,ylabel='Frequency') sns.boxplot(df[i], ax=ax_box, linewidth= 1.0) sns.histplot(df[i], ax=ax_hist, bins = 10,kde=True)

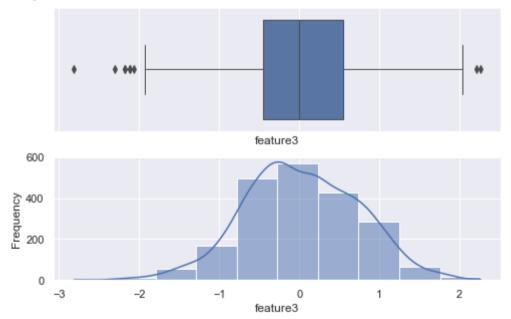
<Figure size 576x360 with 0 Axes>



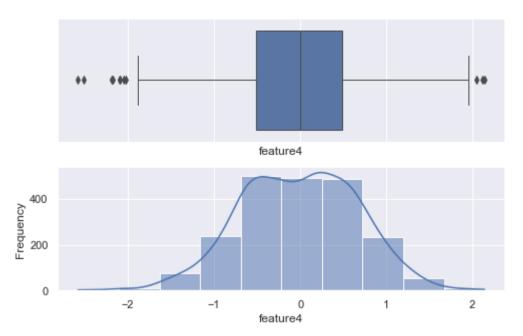
<Figure size 576x360 with 0 Axes>



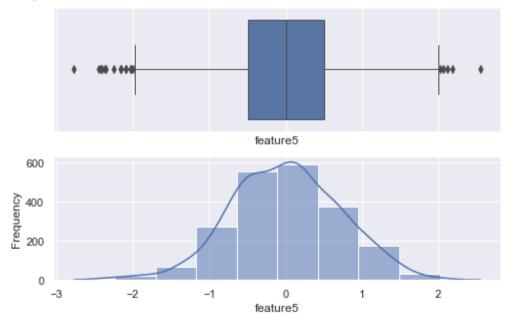
<Figure size 576x360 with 0 Axes>



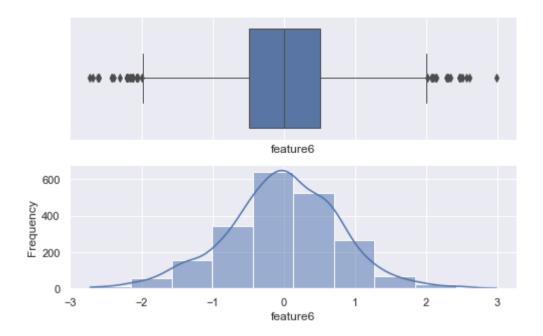
<Figure size 576x360 with 0 Axes>



<Figure size 576x360 with 0 Axes>



<Figure size 576x360 with 0 Axes>



4. Test/train

4.1 Test/train sobre la base de datos inical

```
In [507... df.head(3)
Out[507]:
           feature1 feature2 feature3 feature4 feature5 feature6
                   0.255198 -0.793932 -0.505780 -0.406779 -1.031797
         0 0.445434
        2 -0.057900 -0.458832 0.059801 -0.784782 0.265622 -0.341886
In [508... df.describe().T
```

```
2100.0
                        0.000000e+00 0.647092 2.430146
          feature1
          feature2 2100.0
                       -0.055147 0.734042 -2.594068 -0.544790 -1.260385e-17 0.455210 2.901392
          feature3 2100.0
                        -1.366095e-17 0.543472 2.265903
          feature4 2100.0
                       -0.014072  0.678285  -2.575900  -0.509292
                                                          6.505213e-18  0.490708  2.139141
          feature5 2100.0
                        0.000000e+00 0.507671 2.551230
          feature6 2100.0 -0.017882 0.802946 -2.719578 -0.489815 -1.875670e-17 0.510185 2.987483
         df.shape
In [509...
          (2100, 6)
Out[509]:
         y.head(3)
In [510...
Out[510]:
              1
         Name: target, dtype: int64
In [511... from sklearn.model selection import train test split
         X = df
          X train, X test, y train, y test = train test split(X, y, test size = 0.3, random state=123)
         X train.shape
In [512...
          (1470, 6)
Out[512]:
In [513... y train.shape
         (1470,)
Out[513]:
```

50%

75%

max

4.2 Test/train sin tener en cuenta feature3

Out[508]:

count

mean

min

25%

```
In [514...
from sklearn.model_selection import train_test_split
X_sinF3 = df.drop(['feature3'],axis=1)
```

```
X train sinF3, X test sinF3, y train sinF3, y test sinF3 = train test split(X sinF3, y, test size = 0.3, random state=123)
 In [515... X train sinF3.shape
          (1470, 5)
Out[515]:
In [516... y train sinF3.shape
          (1470,)
Out[516]:
          5. Modelos
 In [564... | from sklearn.ensemble import RandomForestClassifier
          rf = RandomForestClassifier(random state=123)
          rf sinF3 = RandomForestClassifier(random state=123)
          Training the models
          rf.fit(X train, y train)
 In [565...
Out[565]: ▼
                     RandomForestClassifier
          RandomForestClassifier(random_state=123)
          rf sinF3.fit(X train sinF3, y train sinF3)
Out[566]: ▼
                     RandomForestClassifier
          RandomForestClassifier(random state=123)
 In [567... y pred rf = rf.predict(X test)
          y pred rf[:10]
Out[567]: array([0, 3, 3, 2, 0, 2, 3, 4, 3, 3], dtype=int64)
 In [568... y_pred_rf_sinF3 = rf_sinF3.predict(X_test_sinF3)
          y_pred_rf[:10]
```

```
Out[568]: array([0, 3, 3, 2, 0, 2, 3, 4, 3, 3], dtype=int64)
```

6. Evaluación

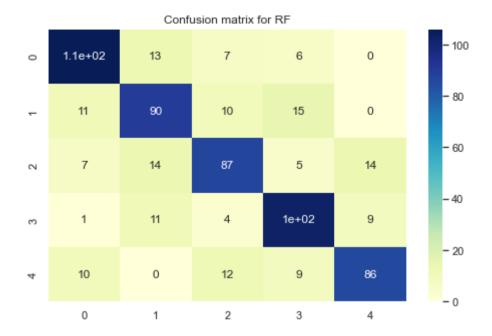
6.1 Métricas del modelo

- F1 score es una métrica muy empleada porque nos resume la precisión y sensibilidad en una sola métrica.
- F1= (2*precisión* sensibilidad)/(precisión + sensibilidad)

donde,

- Matriz de confusión: es una herramienta que permite visualizar el desempeño de un algoritmo de aprendizaje supervisado. Cada columna de la matriz representa el número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real., o sea en términos prácticos nos permite ver qué tipos de aciertos y errores está teniendo nuestro modelo a la hora de pasar por el proceso de aprendizaje con los datos.
- Precisión: Se representa por la proporción de verdaderos positivos dividido entre todos los resultados positivos (tanto verdaderos positivos, como falsos positivos)
- Sensibilidad: Tasa de Verdaderos Positivos (True Positive Rate) ó TP.

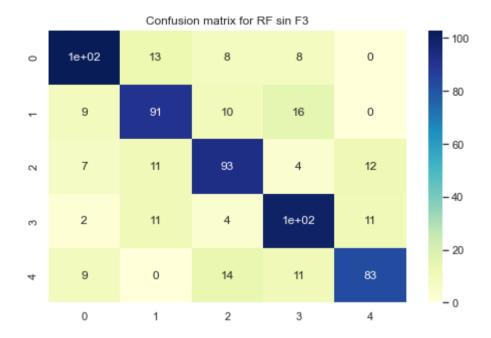
6.1 Resultados Random Forest Classifier con data inicial



```
In [571... from sklearn.metrics import f1_score
f1_rf = f1_score(y_test, y_pred_rf, average='macro')
print("F1 for RF: {:.4f}".format(f1_rf) )
```

F1 for RF: 0.7485

6.2 Resultados Random Forest Classifier sin feature 3



```
In [573... f1_rf_sinF3 = f1_score(y_test_sinF3, y_pred_rf_sinF3, average='macro')
print("F1 for RF: {:.4f}".format(f1_rf_sinF3) )
```

F1 for RF: 0.7457

• Los resultados obtenidos para F1 sin tener en cuenta la variable explicativa feature3, 0.7457 son inferiores a los obtenidos teniendo en cuenta todas las variables 0.7485, por lo que realizaremos los sucesivos ajustes sobre la base de datos inical completa.

7. Cross Validation

• El modelo Random Forest base una F1 más elevada en la validación cruzada y pasa de una F1 de 0.7485 a 0,7744 con una desviación stándar

```
In [575... from pprint import pprint
         print('Parameters currently in use:\n')
          pprint(rf.get params())
          Parameters currently in use:
         {'bootstrap': True,
           'ccp alpha': 0.0,
           'class weight': None,
          'criterion': 'gini',
           'max depth': None,
          'max features': 'sqrt',
          'max leaf nodes': None,
           'max samples': None,
          'min impurity decrease': 0.0,
          'min samples leaf': 1,
          'min samples split': 2,
          'min weight fraction leaf': 0.0,
          'n estimators': 100,
          'n jobs': None,
          'oob score': False,
          'random state': 123,
          'verbose': 0,
           'warm start': False}
```

8. Mejores Parámetros

8.1 Mejores parámetros con RandomSearch

```
In [585... from sklearn.model_selection import RandomizedSearchCV

# Number of trees in random forest
n_estimators = np.linspace(50, 2000, 20, dtype=int)

# Number of features to consider at every split
max_features = [0.4, 'sqrt']

max_depth = [10, 20]
```

```
params= {'n estimators': n estimators,
                 'max features': max_features,
                  'max depth': max depth
        rsearch = RandomizedSearchCV(estimator=rf,
                                 param distributions=params, cv=5,
                                 n iter=40,random state=123,scoring='f1 macro')
        rsearch.fit(X train, y train)
        # Mejores hiperparámetros por validación cruzada
        print("----")
        print("Mejores hiperparámetros encontrados")
        print("-----")
        print(rsearch.best params , ":", rsearch.best score , rsearch.scoring)
        Mejores hiperparámetros encontrados
        {'n estimators': 460, 'max features': 0.4, 'max depth': 10} : 0.7611009642067643 f1 macro
In [553... rf rand=rsearch.best estimator
In [554... # Cross Validation
        from sklearn.model selection import cross val score
        cv rf rand = cross val score(rf rand, X, y, cv=5, scoring='f1 macro')
        print("F1 for RF mean: {:.4f}, std: {:.4f}".format(cv rf rand.mean(), cv rf rand.std()) )
        F1 for RF mean: 0.7691, std: 0.0091
```

8.2 Mejores parámetros con GridSearch

```
# Búsqueda por grid search con validación cruzada
rsearch = GridSearchCV(
      estimator = RandomForestClassifier(random state = 123),
      param grid = param grid,
      scoring = 'f1 macro',
               = None, #multiprocessing.cpu count() - 1,
      n jobs
                = 5, #RepeatedKFold(n splits=5, n repeats=3, random state=123),
      refit
                = True.
      verbose = 0.
      return train score = True
rsearch.fit(X train, y train)
# Resultados
resultados = pd.DataFrame(rsearch.cv results )
resultados.filter(regex = '(param*|mean t|std t)') \
   .drop(columns = 'params') \
   .sort values('mean test score', ascending = False) \
   .head(4)
```

Out[540]:		param_criterion	param_max_depth	param_max_features	param_n_estimators	mean_test_score	std_test_score	mean_train_score	std_train_score
	6	gini	10	sqrt	100	0.763295	0.024434	0.986761	0.001551
	9	gini	10	0.4	100	0.763295	0.024434	0.986761	0.001551
	8	gini	10	sqrt	250	0.759034	0.017669	0.988958	0.001062
	11	gini	10	0.4	250	0.759034	0.017669	0.988958	0.001062

{'n_estimators': 460, 'max_features': 0.4, 'max_depth': 10} : 0.7611009642067643 f1_macro

8.3 Resumen de métricas

```
In [586... print("F1 for RF Base Cros Validation F1: {:.4f}, std: {:.4f}".format(cv_rf.mean(), cv_rf.std()))
print("F1 for RF RandomSearhc Cross_V F1: {:.4f}, std: {:.4f}".format(cv_rf_rand.mean(), cv_rf_rand.std()))
print("F1 for RF GridSearch Cross_V F1: {:.4f}, std: {:.4f}".format(cv_rf_grid.mean(), cv_rf_grid.std()))
F1 for RF Base Cros Validation F1: 0.7744, std: 0.0088
F1 for RF RandomSearhc Cross_V F1: 0.7691, std: 0.0091
F1 for RF GridSearch Cross_V F1: 0.7722, std: 0.0071
```

• Finalmente realizaremos la predicción sobre Random Forest GridSearch con Cross Validation, porque aunque tiene un F1 inferior al modelo Base, la desviación estándar de la métrica es inferior y en el conjunto de las dos métricas es el que consideramos óptimo.

8.4 ROC Curve sobre modelo final

```
In [587... rf_max = rf_grid

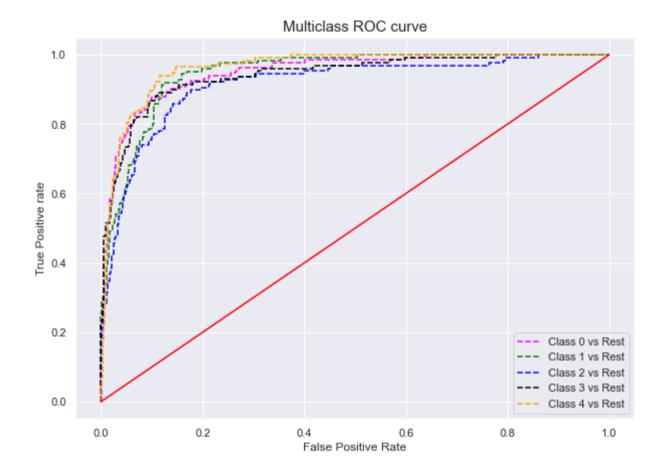
In [588... from sklearn.metrics import roc_curve from sklearn.metrics import roc_auc_score

rf_max_predict_proba = rf_max.predict_proba(X_test)

# roc curve for classes
fpr = {}
tpr = {}
thresh ={}

# defining number of classes
n_class = 5
```

```
for i in range(n class):
    fpr[i], tpr[i], thresh[i] = roc_curve(y_test, rf_max_predict_proba[:,i], pos_label=i)
# plotting
plt.figure(figsize = (10,7))
plt.plot(fpr[0], tpr[0], linestyle='--',color='magenta', label='Class 0 vs Rest')
plt.plot(fpr[1], tpr[1], linestyle='--',color='green', label='Class 1 vs Rest')
plt.plot(fpr[2], tpr[2], linestyle='--',color='blue', label='Class 2 vs Rest')
plt.plot(fpr[3], tpr[3], linestyle='--',color='black', label='Class 3 vs Rest')
plt.plot(fpr[4], tpr[4], linestyle='--',color='orange', label='Class 4 vs Rest')
plt.plot([0, 1], [0, 1], color = 'red')
plt.title('Multiclass ROC curve', fontsize = 15)
plt.grid(True)
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive rate')
plt.legend(loc='best')
plt.show()
```



9. Predicciones sobre el Modelo Final

In [593... df_test.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 900 entries, 0 to 899
Data columns (total 6 columns):
```

Duca	columns (cocal o columns).						
#	Column	Non-	-Null Count	Dtype			
0	feature1	900	non-null	float64			
1	feature2	900	non-null	float64			
2	feature3	900	non-null	float64			
3	feature4	900	non-null	float64			
4	feature5	900	non-null	float64			
5	feature6	900	non-null	float64			
1.4	67	4/61					

dtypes: float64(6)
memory usage: 42.3 KB

```
In [594... final_predictions = rf_max.predict(df_test)
final_predictions
```

array([1, 3, 2, 0, 3, 2, 4, 0, 2, 3, 1, 4, 1, 1, 4, 4, 4, 3, 2, 0, 1, 2,Out[594]: 3, 0, 0, 3, 0, 2, 2, 4, 2, 2, 4, 3, 3, 1, 0, 4, 3, 0, 4, 2, 3, 2, 2, 0, 1, 1, 2, 4, 4, 0, 1, 0, 4, 4, 1, 3, 3, 0, 3, 0, 3, 0, 2, 1, 1, 0, 1, 3, 0, 1, 4, 0, 4, 2, 0, 3, 0, 3, 4, 3, 1, 4, 3, 1, 2, 3, 1, 2, 2, 4, 1, 1, 0, 1, 4, 2, 1, 4, 0, 0, 0, 4, 2, 4, 4, 4, 1, 2, 4, 1, 3, 3, 3, 2, 1, 4, 2, 0, 0, 4, 4, 3, 1, 2, 4, 1, 3, 2, 2, 1, 4, 0, 0, 0, 3, 0, 0, 4, 0, 4, 3, 2, 1, 3, 4, 3, 4, 4, 1, 2, 1, 4, 0, 4, 1, 2, 4, 2, 0, 2, 3, 1, 1, 4, 0, 3, 2, 0, 1, 2, 0, 4, 1, 2, 3, 1, 3, 4, 2, 1, 0, 2, 2, 2, 0, 3, 4, 1, 1, 1, 2, 4, 0, 0, 4, 4, 1, 2, 0, 2, 4, 3, 2, 2, 3, 1, 1, 3, 0, 0, 2, 1, 1, 3, 4, 0, 2, 1, 2, 3, 2, 0, 3, 2, 0, 2, 2, 3, 0, 2, 4, 3, 4, 4, 0, 3, 3, 3, 0, 4, 3, 0, 2, 0, 1, 1, 2, 0, 4, 3, 1, 3, 1, 1, 0, 3, 2, 4, 2, 0, 0, 2, 2, 4, 2, 4, 1, 2, 2, 2, 2, 0, 3, 0, 1, 4, 2, 4, 2, 1, 2, 1, 1, 4, 1, 0, 2, 2, 3, 1, 0, 2, 0, 0, 4, 4, 1, 3, 0, 4, 0, 0, 4, 4, 4, 1, 3, 1, 3, 4, 3, 4, 0, 0, 4, 1, 4, 4, 0, 2, 1, 4, 3, 1, 3, 2, 3, 3, 3, 0, 4, 2, 1, 1, 2, 0, 2, 2, 2, 3, 4, 0, 3, 2, 4, 4, 2, 1, 0, 4, 4, 0, 1, 3, 3, 4, 4, 1, 4, 4, 1, 1, 1, 4, 2, 2, 1, 4, 3, 3, 2, 2, 4, 4, 0, 2, 4, 1, 4, 0, 1, 0, 4, 2, 3, 2, 2, 4, 4, 2, 2, 3, 0, 1, 2, 4, 1, 4, 0, 3, 3, 4, 0, 0, 0, 0, 1, 0, 1, 1, 2, 4, 4, 0, 2, 0, 4, 4, 4, 3, 3, 2, 4, 2, 1, 2, 2, 4, 0, 2, 3, 0, 4, 2, 4, 0, 3, 0, 3, 3, 4, 3, 1, 3, 2, 4, 4, 3, 2, 3, 0, 1, 4, 2, 3, 4, 2, 0, 4, 4, 1, 4, 1, 3, 0, 0, 2, 0, 3, 3, 1, 4, 0, 1, 2, 3, 0, 2, 1, 3, 4, 0, 1, 1, 1, 4, 4, 1, 1, 3, 1, 3, 4, 3, 4, 2, 3, 4, 4, 4, 1, 4, 1, 3, 3, 4, 1, 0, 4, 2, 0, 3, 0, 0, 3, 1, 4, 1, 0, 2, 1, 0, 3, 3, 4, 1, 1, 2, 3, 1, 4, 1, 3, 3, 0, 4, 1, 4, 2, 4, 2, 2, 4, 4, 0, 0, 2, 2, 1, 1, 4, 0, 4, 4, 4, 0, 0, 3, 3, 2, 1, 4, 3, 3, 1, 2, 3, 4, 3, 4, 4, 4, 0, 4, 0, 3, 2, 4, 4, 0, 3, 2, 2, 0, 1, 2, 3, 3, 1, 3, 1, 3, 0, 0, 3, 0, 2, 3, 2, 3, 0, 2, 0, 1, 0, 4, 0, 2, 4, 3, 2, 1, 4, 2, 3, 4, 0, 0, 3, 1, 2, 4, 4, 2, 0, 3, 3, 0, 0, 1, 4, 4, 4, 4, 4, 0, 1, 4, 0, 4, 1, 4, 2, 1, 1, 0, 3, 1, 3, 2, 0, 3, 0, 3, 1, 1, 3, 4, 1, 0, 4, 1, 2, 2, 1, 1, 3, 0, 1, 2, 3, 1, 1, 0, 0, 2, 3, 0, 3, 3, 3, 2, 2, 0, 3, 0, 4, 1, 1, 1, 2, 4, 3, 3, 3, 4, 3, 1, 3, 1, 2, 4, 3, 3, 3, 2, 2, 3, 4, 3, 2, 4, 1, 3, 3, 2, 0, 3, 3, 3, 1, 1, 1, 1, 3, 2, 3, 1, 3, 0, 0, 2, 3, 1, 0, 3, 3, 2, 2, 2, 3, 3, 0, 2, 4, 3, 0, 0, 3, 1, 0, 2, 2, 4, 1, 0, 3, 1, 3, 1, 2, 4, 4, 3, 4, 4, 4, 4, 0, 3, 1, 1, 1, 3, 2, 2, 3, 0, 4, 4, 2, 3, 2, 3, 2, 3, 2, 0, 4, 1, 2, 1, 3, 4, 3, 4, 2, 4, 3, 4, 1, 4, 0, 1, 4, 2, 2, 2, 1, 4, 3, 4, 4, 4, 4, 0, 1, 3, 0, 1, 3, 4, 1, 0, 1, 3, 2, 0, 0, 1, 2, 3, 0, 2, 0, 4, 0, 1, 0, 2, 4, 3, 1, 1, 1, 2, 2, 4, 3, 4, 1, 1, 1, 1, 1, 0, 2, 2, 2, 4, 3, 3, 1, 4, 2, 1, 0, 0, 1, 4, 0, 2, 1, 3, 3, 2, 4, 3, 0, 3, 0, 0, 4, 1, 2, 4, 0, 4, 3, 3, 1, 4, 0, 2, 3, 4, 0, 3, 4], dtype=int64)

8. Conclusions

- RandomForest has been a very stable model and when performing CrossValidation it has given us very consistent results, so we believe that it is a robust model.
- On the other hand, it has been difficult to improve the initial results of the model, we tried several different techniques (RandomSearch, GridSearch) and we have achieved small improvements for the standar desviation.
- It seems that the default parameters already worked well with our data.